

Úvod

Cieľom projektu je osvojiť si **prehľad fungovania v dátovej vede**, základné koncepty a techniky analýzy dát, pochopia, ako fungujú a získajú intuíciu pre ich vhodnú aplikáciu za účelom objavovania znalostí v dátach. Taktiež získajú predstavu, aké otázky vieme pomocou analýzy dát zodpovedať a aplikovať **základné prístupy strojového učenia**. Dôraz je kladený na analýzu a predspracovanie dát, použitie metód strojového učenia, spôsoby ich vyhodnotenia a porovnania.

Projekt sa vypracúva **v dvojiciach** v akceptovateľnej kvalite. Pri riešení sa používa programovací jazyk **Python** a dostupné knižnice pre dátovú vedu ako pandas, numpy, scipy, statsmodels, scikit-learn, atd.. V každej fáze a aktivite sa odovzdáva vykonateľný **Jupyter Notebook** do UIS, ktorý obsahuje všetky vykonané transformácie nad dátami s vhodnou dokumentáciou. Odovzdaný notebook musí obsahovať nielen kód, ale aj jeho výsledky (vypočítané hodnoty, výpisy, vizualizácie a pod.) spolu s komentárom k získaným výsledkom a z toho plynúce rozhodnutia pre ďalšie kroky dátového procesu. Schopnosť dobre komunikovať a prezentovať relevantné výsledky predstavuje významnú zložku hodnotenia.

Pri každej fáze v odovzdanom notebooku uveďte **percentuálny podiel práce** členov dvojice.

Dáta

https://drive.google.com/drive/folders/1ql7dqHpDH7lbdgBB_9i3ZSsoCuhR766F?usp=sharing

(každá dvojica má jeden dataset pod číslom, ktoré máte na cvičení)

Prediktívna údržba (angl. **Predictive Maintenance**, PdM) predstavuje moderný prístup k monitorovaniu technických zariadení, ktorého cieľom je včasná identifikácia vznikajúcich porúch ešte pred ich úplným prejavom. Výskyt porúch vo vozidlách verejnej dopravy počas bežnej prevádzky môže viesť k prerušeniu jazdy, neplánovaným odstávkam a významným ekonomickým stratám. Okrem negatívneho dopadu na prevádzkovateľa spôsobujú takéto situácie aj zníženie spoľahlivosti dopravy a spokojnosti cestujúcich. Tradičné prístupy založené na pravidelnej údržbe alebo pevných prahových hodnotách senzorov často nedokážu zachytiť vznikajúce poruchy dostatočne skoro.

Moderné metódy založené na strojovom učení umožňujú analyzovať kontinuálne zbierané údaje zo senzorov a identifikovať anomálie, ktoré môžu signalizovať blížiacu sa zlyhanie zariadenia. Modely využívajú dáta z rôznych senzorov monitorujúcich stav komponentov, pričom dokážu rozpoznať skryté vzory správania vedúce k poruche. Okrem samotnej detekcie anomálií môžu tieto prístupy podporovať aj predikciu budúcich porúch, odhad zostávajúcej životnosti komponentov či analýzu príčin zlyhania. Vďaka tomu je možné plánovať údržbu pred vznikom kritických porúch, minimalizovať neplánované odstávky a znižovať náklady na opravy.

Cieľom tohto zadania je oboznámiť sa s problematikou prediktívnej údržby, pochopiť možnosti využitia umelej inteligencie v podobe strojového učenia pri detekcii kritického zlyhania systému v senzorových dátach, ktoré umožní včasnú údržbu.

Zadanie projektu

Rail Air-Production-Unit (APU) Predictive Maintenance

The QUEST

Každá dvojica bude pracovať s pridelenou dátovou sadou od 2. týždňa. **Vašou úlohou** je predikovať závislé hodnoty premennej **“failure”** (**predikovaná premenná**) pomocou metód strojového učenia. Budete sa musieť pritom vysporiadať s viacerými problémami, ktoré sa v dátach nachádzajú ako formáty dát, chýbajúce, vychýlené hodnoty a mnohé ďalšie.

Očakávaným **výstupom** projektu je:

1. **najlepší model** strojového učenia;
2. **data pipeline** pre jeho vybudovanie na základe vstupných dát.

Fáza 1 – Prieskumná analýza: 15 bodov

1.1 Základný opis dát spolu s ich charakteristikami (5b)

EDA s vizualizáciou

- (A-1b) Analýza štruktúr dát ako súbory (štruktúry a vzťahy, počet, typy, ...), záznamy (štruktúry, počet záznamov, počet atribútov, typy, ...)
- (B-1b) Analýza jednotlivých atribútov: pre zvolené významné atribúty (min 10) analyzujte ich distribúcie a základné deskriptívne štatistiky a či spĺňa predpísané podmienky a rozsah meraných hodnôt.
- (C-1b) Párová analýza dát: Identifikujte vzťahy a závislosti medzi dvojicami atribútov.
- (D-1b) Párová analýza dát: Identifikujte závislosti medzi **predikovanou** premennou a ostatnými premennými (potenciálnymi prediktormi).
- (E-1b) Dokumentujte Vaše prvotné zamyslenie k riešeniu zadania projektu, napr. sú niektoré atribúty medzi sebou závislé? od ktorých atribútov závisí predikovaná premenná? či je potrebné kombinovať záznamy z viacerých súborov?

1.2 Identifikácia problémov, integrácia a čistenie dát (5b)

- (A-2b) Identifikujte aj prvotne riešte problémy v dátach napr.: nevhodná štruktúra dát, duplicitné záznamy, ktoré môžu vzniknúť po určitých dátových transformáciach, nejednotné formáty, chýbajúce hodnoty, vychýlené hodnoty. V dátach sa môžu nachádzať aj iné, tu nevymenované problémy, resp. menej problémov ako bolo uvedených.
- (B-2b) Kontrola správnosť v dátach
 - či obsahujú abnormálne hodnoty
 - či obsahujú nelogické dátové vzťahy, ktoré sú následkom dátovej kolekcie a anotovania dát
- (C-1b) Vychýlené hodnoty (outlier detection), vyskúšajte riešiť problém min. 2 technikami
 - odstránenie vychýlených alebo odlahlých pozorovaní
 - nahradenie vychýlenej hodnoty hraničnými hodnotami rozdelenia (napr. 5%, 95%)

1.3 Formulácia a štatistické overenie hypotéz o dátach (5b)

- (A-4b) Sformulujte **dve hypotézy** o dátach v kontexte zadanej predikčnej úlohy. Formulované hypotézy overte vhodne zvolenými štatistickými testami.
Príklad formulovania:
flowmeter má v priemere vyššiu hodnotu v stave s failure ako bez nej.
- (B-1b) Overte či Vaše štatistické testy majú dostatok podpory z dát, teda či majú dostatočne silnú štatistickú silu.

V odovzdanej správe (Jupyter notebook) by ste tak mali odpovedať na otázky:

Majú dáta vhodný formát pre ďalšie spracovanie? Aké problémy sa v nich vyskytujú? Nadobúdajú niektoré atribúty nekonzistentné hodnoty? Ako riešite tieto Vami identifikované problémy?

Správa sa odovzdáva v 5. týždni semestra. Dvojica svojmu cvičiacemu odprezentuje vykonanú fázu v Jupyter Notebooku podľa potreby na cvičení. V notebooku uveďte **percentuálny podiel práce** členov dvojice. Správu elektronicky odovzdá **jeden člen z dvojice** do systému UIS do nedele **18.10.2026 23:59**.

Fáza 2 – Predspracovanie údajov: 15 bodov

V tejto fáze sa od Vás očakáva že realizujete **pedspracovanie údajov** pre strojové učenie.

Výsledkom bude dátová sada (csv alebo tsv), kde jedno pozorovanie je opísané jedným riadkom.

- **scikit-learn** vie len numerické dáta, takže niečo treba spraviť s nenumernickými dátami.
- Replikovateľnosť pedspracovania na trénovacej a testovacej množine dát, aby ste mohli zopakovať pedspracovanie viackrát podľa Vašej potreby (iteratívne).

Keď sa pedspracovaním mohol zmeniť tvar a charakteristiky dát, je treba realizovať EDA opakovane podľa Vašej potreby. Bodovať techniky znovu nebudeme. Zmeny zvolených postupov dokumentujte. Problém s dátami môžete riešiť iteratívne v každej fáze a vo všetkých fázach podľa potreby.

2.1 Realizácia pedspracovania dát (5b).

- (A-1b) Dáta si rozdeľte na trénovaciu a testovaciu množinu podľa vami preddefinovaného pomeru. Ďalej pracujte len s **trénovacím datasetom**.
- (B-1b) Transformujte dáta na vhodný formát pre strojové učenie t.j. jedno pozorovanie musí byť opísané jedným riadkom a každý atribút musí byť v numerickom formáte. Iteratívne integrujte aj kroky v pedspracovaní dát z prvej fázy ako celok.
- (C-1b) Transformujte atribúty dát pre strojové učenie podľa dostupných techník minimálne: scaling (2 techniky), transformers (2 techniky) a ďalšie. Cieľom je aby ste testovali efekty a vhodne kombinovali v dátovom pipeline (od časti 2.3 a v 3. fáze).
- (D-2b) Zdôvodnite Vaše voľby/rozhodnutie pre realizáciu (t.j. zdokumentovanie)

2.2 Výber atribútov pre strojové učenie (5b)

- (A-3b) Zistite, ktoré atribúty (features) vo vašich dátach pre ML sú informatívne k predikovanej premennej (minimálne 3 techniky s porovnaním medzi sebou).
- (B-1b) Zoradte zistené atribúty v poradí podľa dôležitosti.
- (C-1b) Zdôvodnite Vaše voľby/rozhodnutie pre realizáciu (t.j. zdokumentovanie)

2.3 Replikovateľnosť pedspracovania (5b)

- (A-3b) Upravte váš kód realizujúci pedspracovanie trénovacej množiny tak, aby ho bolo možné bez ďalších úprav znovu použiť **na pedspracovanie testovacej množiny** v kontexte strojového učenia.
- (B-2b) Využite možnosti **sklearn.pipeline**

Správa sa odovzdáva v 7. týždni semestra. Dvojica svojmu cvičiacemu odprezentuje vykonanú fázu v notebooku podľa potreby na cvičení. Uveďte percentuálny podiel práce členov dvojice. Správu elektronicky odovzdá **jeden člen z dvojice** do systému **UIS** do nedele **01.11.2026 23:59**.

Fáza 3 – Strojové učenie: 20 bodov

Správa sa odovzdáva v 10. týždni semestra. Dvojica svojmu cvičiacemu odprezentuje vykonanú fázu v Jupyter Notebooku na cvičení. V notebooku uveďte percentuálny podiel práce členov dvojice. Následne správu elektronicky odovzdá **jeden člen z dvojice** do systému **UIS** do nedele **22.11.2026 23:59**.

Aktivity na cvičení: 10 bodov

Správa sa odovzdáva v 12. týždni semestra. Dvojica svojmu cvičiacemu odprezentuje vykonanú fázu v Jupyter Notebooku na cvičení. V notebooku uveďte percentuálny podiel práce členov dvojice. Následne správu elektronicky odovzdá **jeden člen z dvojice** do systému **UIS** do nedele **06.12.2025 23:59**.